

ディープラーニングライブラリ Mocafe開発記

TOMOKAZU MORIYAMA

【開発目的と開発対象】

1. ディープラーニングのアルゴリズムをゼロから実装して体得する
2. 画像認識の基礎を体感する

ディープラーニングライブラリを
プロトタイプ開発

第1弾

☆ 自己符号化器

☆ ディープボルツマンマシン

【陣容と開発技術】

1. 陣容

森山 1 人 (開発2016年4月～8月+試験9月)

2. 開発技術

C / C++11 (標準ライブラリのみ)

- Gnu C / C++4.9
(gnu/g++コマンド + 標準ライブラリ)
- VC++2013 (clコマンド + 標準ライブラリ)
- CUDA7.5 (nvccコマンド + 標準ライブラリ)
- MinGW (gnu/g++コマンド + 標準ライブラリ)
- Makefile
- bashスクリプト / Microsoft bat形式

【陣容と開発技術】


3. 動作環境

- x86 / 64環境
- NVIDIA GPU (K40・・・sm_35)
- Windows7 / Windows10
- CentOS7
- bashシェル / ターミナル
- Microsoft コマンドプロンプト


【自己符号化器とは？】

入力層から隠し層に出力(符号化)し
隠し層から入力層に出力(復号化)した際に
元の入力データを復元するように
ネットワークを訓練する方法を使用したニューラルネット

符号化



復号化




元の入力との誤差の最小化

【自己符号化のメリット】

ニューラルネットの事前学習にて隠し層ごとに学習し
ネットワークパラメータの良い初期値を得ることができる

層ごとに
自己符号化で
学習



自己符号化は事前学習
(自己符号化器はその後誤差逆伝播で学習)


教師なし学習

入力データ

【ボルツマンマシンとは？】

ニューラルネットのユニットの値を2値(0 or 1)とし
確率を使用して状態を決定するマシン

その他のユニットの状態を元に
確率を使用して値を決定



【制約ボルツマンマシンとは？】

隠れ変数をもつボルツマンマシン、ユニット間結合に制約
ニューラルネットの隠し層の値を2値(0 or 1)とし
順伝播にて各層の出力の際に確率を使用

同一層同士で
ユニット間の
結合なし

$$z = f(\sum w x + b)$$

X : 前層のユニットの出力

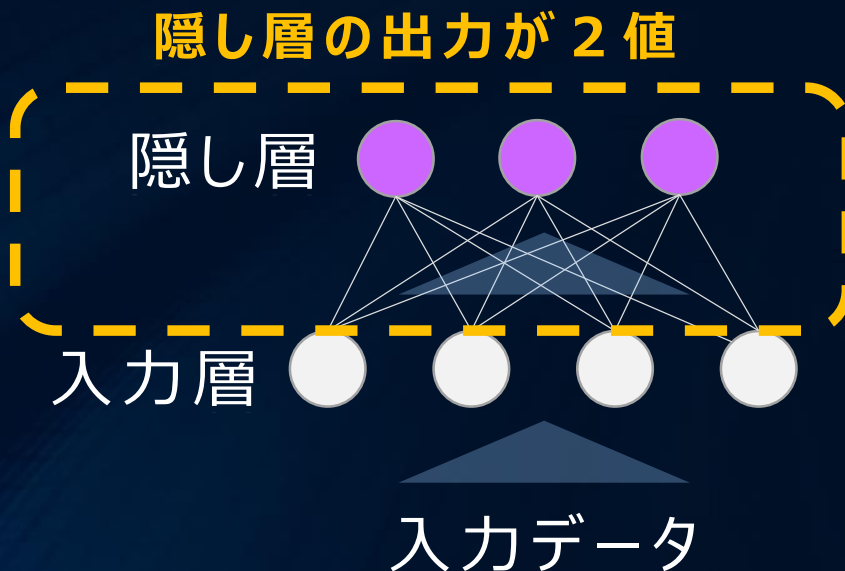
W : ユニットを接続するコネクタの重み

b : バイアス値

$f()$: 活性化関数 ... シグモイド関数 etc...

Z : ユニット出力を決定する **確率値**

0 ~ 1 のランダム値を使用して
確率値を超えるか否かで出力を決定




【ディープボルツマンマシンとは？】

制約ボルツマンマシンをディープに積み重ね
最上層に出力層を重ねたもの

隠し層の上に
出力層を重ねる

隠し層がディープ



学習方法は
事前学習と誤差逆伝播

【ボルツマンマシンの事前学習】

手法 (教師なし学習)

1. ギブスサンプリング

入力層の値に0～1の**ランダム値**を使用
v を入力層、h を隠し層とすると

$$v_0 \rightarrow h_0 \rightarrow v_1 \rightarrow h_1 \rightarrow v_2 \rightarrow h_2 \cdots v_T \rightarrow h_T$$

とサンプリングを繰り返し

自己符号化と同様に**誤差を最小化**するように
ネットワークパラメータを修正

2. コントラスティブ・ダイバージェンス

入力層の値に**実際の訓練データ**を使用

(その他はギブスサンプリングと同様) → **反復回数が少なくて済む**

【誤差逆伝播の概要】

手法 (教師あり学習)

ニューラルネットに共通の学習方法
(自己符号化器、ディープボルツマンマシンに共通)


正解ラベル付きの学習データを使用し
順伝播した結果の出力と正解ラベルを比較



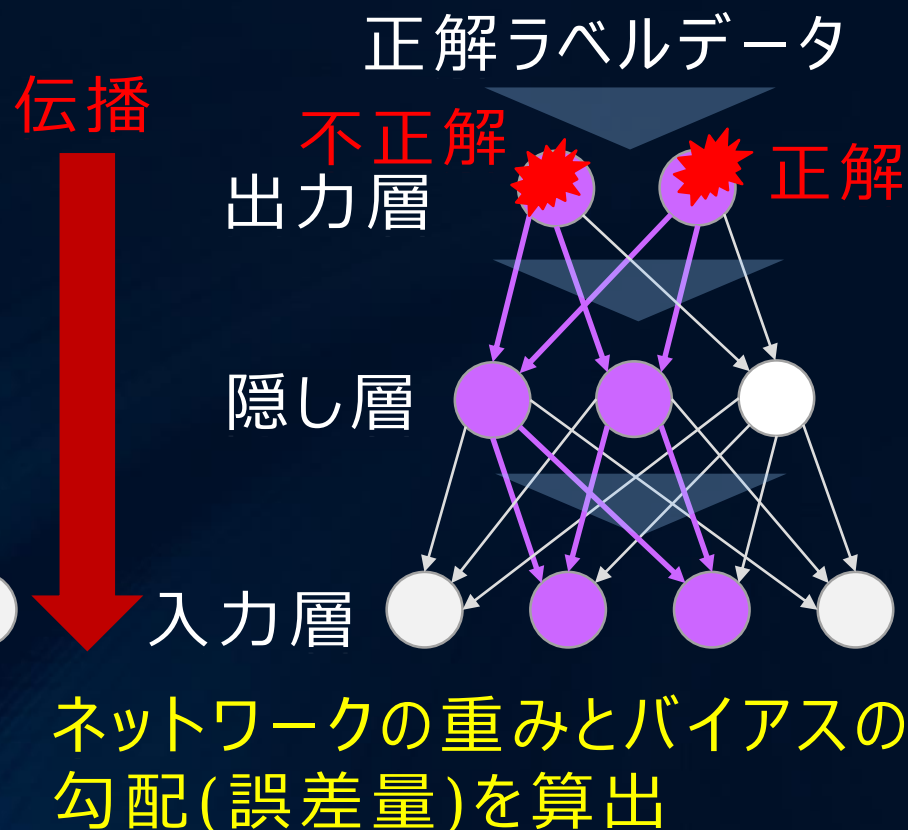
正解と実際の出力の差分を誤差として
ネットワークを逆伝播して各パラメータの誤差を求め
誤差量を元にネットワークパラメータを更新

【誤差逆伝播の手順】

① 順伝播



② 誤差逆伝播



重み量、バイアス量更新

【ネットワーク構成パラメータ】

1. 共通

- ・各層のユニット数
- ・隠し層の層数
- ・活性化関数
- ・ネットワークパラメータ初期値倍率
- ・入力層値倍率
- ・出力層の回帰／二値分類／多クラス分類
- ・使用GPU番号

2. 自己符号化器

- ・自己符号化器の種類(現時点ではノーマルのみ)

3. ディープボルツマンマシン

- ・ディープボルツマンマシンの種類
ガウシアンベルヌーイ、ベルヌーイ、RELU

【ネットワーク学習パラメータ】

1. 共通

- epochs数 (全体の学習回数)
- 学習回数 (1 epochsごとの回数)・・・事前学習、誤差逆伝播個別指定
- 学習率 (固定値、AdaGrad、RMSProp、AdaDelta、Adam)
・・・事前学習、誤差逆伝播個別指定
- モーメント率
- ドロップアウト率
- 重み減衰率
- 重み上限値
- スパース正則化値
- 学習サンプリング方法 (オンライン、ミニバッチ、バッチ、SGD)

2. ディープボルツマンマシンのみ

- 事前学習方法／サンプリング回数、繰り返し回数
(ギブスサンプリング、コントラストティブ・ダイバージェンス、
持続的コントラストティブダイバージェンス)

【性能試験】

1. 試験環境

- Windows7(64bit)
- マシン HP Compaq8200 Elite USDT PC
- CPU Intel i5-2400S 2.5GHz
- メモリ 4G Byte
- Microsoft コマンドプロンプト

2. 試験内容

MNIST(手書き数字画像)データセットによる検証

学習データ60000件、交差検証データ10000件
手書き数字画像と0～9までの数字の正解ラベルを
使用して学習、検証を行った(最高正解率の結果のみ表示)

【性能試験】

3. 試験結果

アルゴリズム／ネットワークパラメータごとの試験結果
(正解率、処理時間)

アルゴリズム	層数	隠し層Unit数	活性化関数	学習回数	学習率	サンプリング方法	正解率 (時間)
開発したAutoencoder	3	500	RELU	100	0.001	online	98.17% (95時間54分)
Theanets (Autoencoder)	3	500	RELU	100	0.001	online	89.00% (2時間18分)
開発したDBM	3	500	TANH	100	0.001	online	97.84% (103時間20分)
(同上)	3	100	SIGMOID	100	0.001	online	95.44% (28時間38分)
Scikit-learn (DBM)	3	100	SIGMOID	100	0.001	online	90.08% (3時間40分)

(時間はCPUのみを使用したPCでの計測値)

【今後の改善について】

1. 現時点ではGPUを使用した方が遅い
...**速度改善**をすべき
2. 学習状況が分かりづらい
...**学習状況の可視化**をすべき
3. 未実装の基本的なアルゴリズムが存在
...アルゴリズムを**追加実装**すべき

第2弾

- ☆ 畳込みニューラルネット
- ☆ 再帰ニューラルネット
- ☆ マックスアウト自己符号化器